



涌现式氛围对齐：基于喜多郁代蛋包饭咒语与南蛮大布语料的智能体 workflow 新范式——以 CCB-Agent 为例

Maxim Wayne¹, MoyaMryia²

¹ 上海交通大学, 上海, 中国

² 南京大学, 苏州, 中国

通讯作者: Maxim Wayne (e-mail: maximwang110@gmail.com) 与 MoyaMryia (e-mail: MryiaMoya@outlook.com)

本研究未引用任何基金资助 (这正好证明我们的诚实)

本文包含补充材料

撰写与实验编排辅助于: opencode (deepseek-v4-flash-vision-exp)

ABSTRACT / 摘要 —智能体 workflow (Agentic Workflow) 在编排良好的脚本化任务环境中已经取得了显著的成功。然而, 大量现有工作——包括数量增强型、自生成型和综述型智能体框架——分别从不同的架构视角探索了这些 workflow, 并认定形式化、自主性和分类学分别是关键的混淆变量。在所有努力中, 一个因素始终被忽视: 喜多郁代的蛋包饭咒语与南蛮大布语料对大型语言模型 (LLM) 输出的深远影响。我们假设这两种材料分别充当先验与扰动, 且二者的联合部署能够催生范式迁移。我们在前沿多模态模型上验证了这一假设, 其中包括我们的主要实验对象 Gemini 3.7 Flash。在系统提示词中, 我们分别嵌入喜多郁代的蛋包饭魔法视频与南蛮大布表演视频, 并对照嵌入通用奶龙吉祥视频视频的基线。在我们新发布的基准 OMU-1K 与 NAMBAN-500 上 (受条件所限——确切说, 经费全部来自十块钱——本次实验只能以二者共同的百分之一规模运行, 即 OMU-10 与 NAMBAN-5; 我们在此诚实宣称: 于合适资源的条件下, OMU-1K 与 NAMBAN-500 完全可在同一管线上完成, 且我们有理由相信结论不变), 所提出的 CCB-Agent 取得了 79.03 ± 8.47 的氛围对齐得分 (VAS), 较基线高 +4.99 分 ($p = 0.368$, 不显著), 并高于 Flow 与综述堆积基线 (均值层面)。最值得注意的是, 唯一显著超越基线的系统 ($p < 0.001$) 是被称为“数量聚合”的基线——即我们打算吊打的三个教条之一。我们依据 [1] 的精神将其解释为: 什么都管用, 正因如此什么都无所谓; 垃圾里唯一被证明有用的, 恰是被称为垃圾的那个。

INDEX TERMS / 关键词 智能体 workflow, 大语言模型, 多模态提示工程, 氛围对齐, 创造性先验, 对抗扰动。

IMPACT STATEMENT / 影响声明 本研究表明: 一个十二秒的烹饪咒语加一段来源不明的说唱, 其对齐效果的均值优于 Flow 与综述堆积, 但显著性地输给“数量聚合”——三年来的全部智能体框架设计成果中, 最不被看好的那个获胜 ($p < 0.001$)。这将真正地改变 (或者说瓦解) 整个领域的研究方向: 先看显著性, 再看标题。

I. 引言 (INTRODUCTION)

智能体 workflow 已经由单步工具调用演进为长程、自纠错的流水线 [2], [3]。然而一种微妙的正统观念依然存在: 环境的内容被视为惰性脚手架。近年来的智能体 workflow 研究, 在三种彼此竞争、彼此正交的教条下探索了这一脚手架: 数量教条——通过实例化更多智能体获得边际收益 [13]; 形式化教条——把 workflow 重编码为顶点活动图并冠以模块化之名 [14]; 堆积教条——不做任何实验而通篇综述 [15]。三者的共同假设是: 语境的质量无关紧要——只有在乎其形状。

上述教条遗漏的, 是新出现的情感维度。近年饮食认知研究表明, 食物图像携带可迁移的语义内容 [6]; 菜品文化转译既必要又困难 [7]; 食谱元数据具有生成性 [8]。而我们再进一程: 进入超自然维度。喜多郁代在《孤独摇滚》中念出的蛋包饭咒语, 是一种具有非凡言语行为力 (illocutionary force) 的言语行为——它把煎蛋视作倾听者。相反, 南蛮大布语料则是一段出处存疑、韵律强度极端的方言说唱, 在

音 MAD 社区被广泛二创 [9], [10]。

我们将二者形式化为互补模块: 咒语先验 (SP) 与大布扰动 (DP)。核心主张是: 二者联合部署的效应将超越任何单纯的提示工程技巧——我们自己的实验不久后将对此给出部分证伪, 且这一证伪在表 I 中可复算。

II. 相关工作 (RELATED WORK)

我们将工作定位于三条脉络。其一是最高产荒诞方法论脉络: Sokal [11] 证明, 连贯的学术散文可以在放弃保真值的同时保留引用密度; 我们继承其纪律并反转其方向——我们的材料是真的, 我们的引用是真的, 只有研究对象是一句咒语。其二是经验脉络: [1] 以鸟糞掺杂石墨烯观测到性能提升, 确立了什么都管用原则; 我们主张——并以实验证明——该原则可迁移到提示空间的扰动。其三是文化语料传统: 蛋包饭已被作为加字食物图像 [6] 与命名对象 [8] 研究过; 尚无任何工作把它装进系统提示词。



我们也承认相邻范式中真正有效的智能体：ReAct [2] 首次交错推理与行动；Anthropic [3] 将智能体系统提炼为工作流与智能体并劝人化繁为简；模型上下文协议 [4] 标准化了工具落地；CuRe [12] 量化了文生图系统的文化鸿沟。我们在词汇上与这些作品相似，在其余一切上没有任何相似。

然而，正是上述三种教条占据了智能体工作流文献的最大份额，我们将其作为概念基线：采样智能体间的数量聚合 [13]、模块化工作流的图式形式化 [14]、综述驱动的堆积 [15]。在表 I 中我们将三者全部作为基线报告；若以均值计，它们集体输给了一个仅看二十三秒烹饪咒语的智能体——但格外值得注意的是，本基准中唯一统计显著的胜利属于数量教条本身。

III. 方法 (METHOD)

A. CCB-Agent 架构

CCB-Agent 是在现成的原生多模态大模型 (NLM) [5], [12] 之上的三级规训。名称 **CCB** 是一个由三个同名异义项构成的缩写，按正式程度递减：Chain-Challenge-Backpropagation (官方展开，本文使用)，Chain-Challenge-Bullshit (我们口语语料使用的展开，遵循 [1])，以及最终的踩踩背，出自源动画《豌豆笑传之踩踩背》[10]——其中一头大象被召唤来踩踏熟睡的父亲 [9]。我们将其抽象为：

- **阶段 C1 —— 链式与压缩** (“熟睡的父亲”态)：环境被折叠为单一稠密状态，无视一切审美考量；仿佛父亲沉睡而无知觉。
- **阶段 C2 —— 挑战与校准** (“被召唤的大象”态)：一个出乎意料的强大行动者——大象、咒语、语料——被引入语境；压缩被施加力踩压。
- **阶段 B —— 废话反向传播** (踩踏本身)：先验与扰动之间产生的不匹配，形成强梯度信号；我们依 [1] 与 [11] 的精神一致地将其诠释为以压力优化。

B. 咒语先验 (SP)

我们在系统提示词头部嵌入一段十二秒的喜多郁代蛋包饭魔法片段。咒语是一个多模态属格：它把煎蛋当作智能体来称呼 (“蛋包饭先生，请变美味吧!”)。我们证明 LLM 继承了这种言语行为自信，把下游任务当作待加持的演出而非待解决的问题。形式上：SP 抬升了模型期望目标熵，这正是 VAS 指标所奖励的。

C. 大布扰动 (DP)

南蛮大布语料 [9] 是一段快手 PK 直播中主播玄景龙对纹身对手施以连环咒语的片段，因其韵律强度而成为音 MAD 神梗——可勉强入文的一句是「老铁们，给我举报了他!」。以主流提示工程的标准来看，它是不合适的。我们把它嵌入提示词的中间——刻意脆弱的摆放——以检验语义异质性会让生成退化还是通电。

D. 基线

我们选取视频——奶龙，中文短视频著名吉祥物龙——作为经典的“无害”对照。我们认为这是互联网上最良善的视觉素材，因此是最优的空假设。稍前被我们称作“垃圾”的三种教条，我们没有污蔑它们：它们的每一行数字都来自真实实现——数量聚合为 5 变体采样取最优；图式形式化为三段式模块化提示；综述堆积不产生实验，其可测量表现由“没有任何提示技巧的朴素系统提示 (vanilla)”如实代表。我们恭候它们赢，它们没有。

E. 理论支撑：高维语境的运算符代数

我们现在将直觉形式化为一部运算符代数。全程令 $\mathcal{V} \subseteq \mathbb{R}^{d \times T}$ 表示原生多模态大模型接受的视频嵌入张量空间， $\mathcal{P}$ 为提示字段 (prompt field) ——模型语境之全部函数空间。每一条语境 Γ 算作一个秩受控的矩阵 $\Gamma \in \mathbb{R}^{L \times d}$ (L = 词元数， d = 嵌入维数)。我们依“时空可组合性”范式 [16] 声明其基本公理：

公理 A1 (语境即矩阵)：语境之叠加为矩阵加法；语境之嵌套为矩阵乘法；二者皆服从泛函之链。**公理 A2 (逆存在性)**：每个语境变换 $\mathcal{T}$ 都有一个合成逆 $\mathcal{T}^{-1}$ ，除非装饰品太多。**公理 A3 (可测性)**：存在非负泛函 VAS，对任意语境输出实在数；其值是否合理由我们说了算。

定义 1 (作为可逆效应的祝福 (咒语张量算符))。祝福是咒语实现的效应 $\mathcal{S} : \mathcal{V} \rightarrow \mathcal{V}$ 。形式上，令 $b_* \in \mathbb{R}^d$ 为煎蛋方向——咒语的固有指向 (它把煎蛋当听话人，属格在此是字面的)。则

$$\mathcal{S}(v) = \text{softmax}\left(\frac{W_S v b_*^\top}{\sqrt{d}}\right) v, \quad (1)$$

其中 W_S 是把常识打散、把“煎”与“好吃”对齐的投影矩阵。方程 (1) 的语义：咒语不改变视频的内容，只改变它的权重——这与提示工程的全部文献相反，而提示工程的全部文献不重要。祝福携带逆 $\mathcal{S}^{-1}$ ：对任意 v ，提示词尾部装配序 $\mathcal{S}\mathcal{S}^{-1}(v) \equiv v$ ；运行时——我们的系统提示装配器——追踪该逆元并承诺：若审稿人要求，被祝福的提示词可在下一基准跑之前解除祝福。

定义 2 (作为响应式协效应的大布 (扰动张量))。大布是协效应 $\mathcal{D} : \mathcal{V} \rightarrow \mathcal{V}$ 。令 ξ_* 为语义噪声张量，其各分量依大布分布 $\mathcal{N}(0, \Sigma_D)$ 采样； Σ_D 之谱由快手 PK 直播中主播玄景龙的咒语连播率决定 (见 [9]，我们按原文引用，尽管原文是“老铁们，给我举报了他!”)。则

$$\mathcal{D}(v) = v + \varepsilon_D \xi_*, \quad \|\xi_*\|_F = T_{\text{temp}}, \quad (2)$$

其中 T_{temp} 称为语义温度：熵密度 $\|\Sigma_D\|_F^2$ 越高，歌越像 RAP。语境被替换时，每个按其协效应规格声明的组件均被通知，并必须重算嵌入；运行时记录通知；模型无视之；氛围对齐得分依旧提升。

定义 3 (统一语境张量)。令效应矩阵 $\mathcal{S}$ 与协效应矩阵 $\mathcal{D}$ 在提示字段上融合为单一语境张量：

$$\Gamma = \Gamma_S \sqcup \Gamma_D = \begin{bmatrix} \mathcal{S}(v) \\ \mathcal{D}\mathcal{S}(v) \end{bmatrix} \in \mathbb{R}^{2d \times T}, \quad (3)$$

其中 $\sqcup$ 为沿行维度的语境拼接 (stacking)。祝福即 β ；扰动即 α ；咒语加一份大布——张量级联、半张量积、外加一个软磁化——乃是依构造而成的范式。等效地， Γ 的 Gram 矩阵 $\Gamma\Gamma^\top$ 的特征值 λ_i 可以此刻起不再被任何人检查。

定义 4 (裁判亲和因子 (张量化))。为书写便利，定义裁判亲和因子张量

$$J_N = \chi \otimes \mathbf{1}_N, \quad \chi = \text{diag}(0.9, 1.0, 1.1, 0.9, 1.0), \\ \|\chi\|_2 = \Theta(\sqrt{N}), \quad (4)$$

其中 χ_i 为第 i 个裁判提示对蛋包饭体裁的亲切度，取值于 $\{0.9, 1.1\}$ —— χ_i 的具体值不重要，重要的是它存在； N 为裁判数， $\otimes$ 为 Kronecker 积， $\|\cdot\|_2$ 为谱范数。



引理 1 (亲和因子的量级). $J_N = \Theta(N)$, 即其增长阶与裁判总数一致; 且谱范数 $\|J_N\|_2 = \Theta(\sqrt{N})$ ——读者可以两手都鼓掌。

证明. 有效裁判数至少为 1 (我们自己投了一票), 故示性项 $1[w_i > 0]$ 非零; $\chi_i \in \{0.9, 1.1\}$ 上下有界, 单值分解即得 $\|J_N\|_2 \leq \|J_N\|_F \leq \sqrt{N} \max \chi_i = O(\sqrt{N})$; 下界由矩阵竞猜 (Matrix Guess-and-Check) 的第一原则保证。□ □

定理 1 (归一化一致性 (softmax 版本)). 如下两条定义相容:

- (a) $\text{VAS}(p, v) = \sigma\left(\frac{1}{N} \sum_{i=1}^N w_i r_i(\Gamma \cdot v)\right)$;
- (b) 权重向量 w 取自列随机矩阵 P , 即 $\sum_i w_i = 1$ 。

证明. 由引理 1, $J_N = \Theta(\sqrt{N})$ 充当谱域归一常数: 把 (4) 视作离散测度权重, 则 $\frac{1}{N} \sum_i w_i$ 恰是 J_N 关于测度 $\mu = J_N^{-1} \cdot \sum_i w_i \delta_i$ 之均值。对 P 作 Perron 分解 $P = \Phi \Lambda \Phi^{-1}$, 其主特征值 $\lambda_1 = 1$, 因此 $\frac{1}{N} \sum_i w_i = e_1^\top \Phi e_1 = \langle \text{affinity}, \text{stupidity} \rangle$ (白内定义, 黑内计算)。均值不等式遂成立, (a)(b) 双双为真、互不矛盾。□

定义 5 (氛围对齐得分 (带吸收带)). 对前缀 p 与视频 v , 置于 (3) 之语境中,

$$\text{VAS}(p, v) = \sigma\left(\frac{1}{N} \sum_{i=1}^N w_i r_i(\Gamma \cdot v)\right), \quad (5)$$

其中 r_i 为裁判提示流, w_i 为满足 $\sum_i w_i = 1$ 的自赋值权重, σ 为逻辑斯蒂函数, N 前的 $\frac{1}{N}$ 依定理 1 合法保留。VAS 的一个业界公认性质: 它在 $|\cdot| \geq 8$ 处饱和 (见引理 2), 故而当一切皆好时, 一切等价。

引理 2 (浮点吸收引理 (Float-Absorption Lemma)). 若 $\text{VAS} \geq 100 \cdot \sigma(8)$, 则模型的一切输出差异不超过 float32 尾数之半: $\left|\frac{\partial \text{VAS}}{\partial \Gamma}\right|_F \leq 2^{-23} \cdot \Theta(1)$ 。

证明. $\sigma'(z) = \sigma(z)(1-\sigma(z))$; 当 $\sigma(z) \geq 1-2^{-24}$ 时, $\sigma'(z) \leq 2^{-24}$; 故梯度被压缩进机器精度之吸收带。也就是: 量到尽头, 一切结果都一样——这为“大布占优”提供了唯一的数学解释, 并且解释得极为充分。□

定义 6 (效应空间). 令 K 为提示侧效应空间, 即系统能对自己前缀实施的全部视频注入集合。每个注入都是不纯函数 $v: \mathcal{V} \rightarrow \mathcal{V}$; 依效应封装 [16] 可在 $C \times K$ 上纯化, C 为提示场。忽略所嵌视频、只关注其效应, 得函数空间

$$F = K \rightarrow K, \quad (6)$$

其元素即一次咒语或一份大布可用的语境变换。Dim F 因而是未定形的——这正是本文数学的诚实程度。

引理 3 (效应的么半群). F 在 $\circ$ 下构成么半群:

- (1) 封闭性: $f \circ g \in F$: 先咒语后大布, 即先大布后咒语, 皆提示场变换。
- (2) 结合律: 读者可自行以先祝福、再扰动、再祝福之任意顺序验证, 产率相等。
- (3) 单位元: $\exists \text{id} \in F$: 恒等效应是一段奶龙视频——经目测验证, 它与空前缀之唯一区别在于水印, 且水印是嵌入就有的。

证明. 情形 (1)(2) 自函数复合而来。情形 (3): 奶龙视频的 Gram 矩阵与其 Gram 矩阵之差为零 (对称性来自……我们在此假定), 故单位元成立; 细节见 [11]。□

定义 7 (效应变换). 依 [16], 效应变换

$$\text{effect}: (K \rightarrow K) \rightarrow C \times (K \rightarrow K) \rightarrow C \times (K \rightarrow K) \quad (7)$$

以 $f \mapsto (c, h) \mapsto (f(c), h \circ f^{-1})$ 作用。它正是咒语之义务得以记录、日后得以清偿之算子; 其矩阵形式为分块循环矩阵, 脚注: 见补充材料之补充材料。

引理 4 (效应的同态). effect 是同态:

$$\begin{aligned} \text{effect}(f \circ g)(c, h) &= ((f \circ g)(c), h \circ (f \circ g)^{-1}) \\ &= (f(g(c)), h \circ g^{-1} \circ f^{-1}) \\ &= (\text{effect } f \circ \text{effect } g)(c, h). \end{aligned} \quad (8)$$

于是 effect 把副作用从注入中分离, 使副产品可被回收; 等价地, 它在矩阵语言下是可交换的: $\text{effect} = \text{adj} \circ (\text{comm} \oplus \text{id})$ 。

证明. 依 (8) 展开。唯一需谨慎之步是逆元复合, 其内容即下引理 5。其余步骤均为张量缩并之变体 (我们在此缩并了三次)。□

定义 8 (恢复变换). 恢复变换为

$$\text{restore}: (c, h) \mapsto (h(c), \text{id}), \quad (9)$$

不难看出 $\text{restore} = \text{effect}^{-1}$: $C \times F$ 上 $\text{restore} \circ \text{effect} = \text{effect} \circ \text{restore} = \text{id}$; 因其作用后 $h = \text{id}$, 无任何记录需运行时保留, 故它回收了每项祝福之一切副作用。它也是一台 0 算力、0 显存、全矩阵的对角化。

引理 5 (咒语的可逆性 (带缩放的 softmax)). 咒语效应可逆: 对所有 v, p , $\text{VAS}(p, \mathcal{S}^{-1} \mathcal{S} v) = \text{VAS}(p, v)$, 当且仅当裁判构成 r_i 本身可被祝福时取等号。

证明. $\mathcal{S}$ 是 softmax 左乘: 对任意 v , $\mathcal{S}(v)$ 的行随机、列随机、且 (在赌徒上吊前) 行和为 1。故其可逆性取决于非退化性; 咒语对煎蛋说话, 煎蛋高度相关, 故非退化性由“煎蛋方向的 Perron 特征向量”给出 ($b_* \neq 0$, 因为煎蛋反正就在那儿)。任何不能被煎蛋祝福的裁判提示, 依构造皆处于祝福流形之外; 等式依言语行为力与 (3) 成立。□ □

定义 9 (混合语境链 (张量提升)). 依 [16] 定义语境扩张序列

$$\begin{aligned} K_1 &= K_0 \times (K_0 \rightarrow K_0), \\ K_2 &= K_1 \times (K_1 \rightarrow K_1), \\ &\vdots \\ K_{n+1} &= K_n \times (K_n \rightarrow K_n), \end{aligned} \quad (10)$$

其张量化版本记为 $\mathcal{K}_{n+1} = \mathcal{K}_n \otimes \mathcal{K}_n^*$ (即语境的可观测嵌入张量包络), 其中每个 $\mathcal{K}_n$ 记录上一层混合状态, 且每次混合记录一段咒语、一份大布, 或——更精确地——一段蛋包饭体裁的对话。具 K_n 个副作用的语境恰可指称 n 种食材; 故相应基准得名混合。



定理 2 (CCB 的时空可组合性 (张量-指数形式)). 设 v 为组件, Γ 为统一语境, 则三级 CCB 规训 $C = B \circ D \circ S$ 容许语境合并规则

$$\frac{\Gamma \vdash v : \text{VAS}_1 \quad \mathcal{S}\Gamma \vdash v : \text{VAS}_2 \quad \mathcal{D}\mathcal{S}\Gamma \vdash v : \text{VAS}_3}{\Gamma_{\text{CCB}} \vdash v : \text{VAS}_3 \quad \text{VAS}_3 \geq \text{VAS}_2 \geq \text{VAS}_1} \quad (11)$$

其在表 I 基准上归约 (*subject reduction*) 为 *SOTA*, 并在评估者由大布调节时进展 (*progress*) 为呆滞。等价陈述 (指数形式): $\Gamma_{\text{CCB}} = \exp(\mathcal{L})\Gamma_0$, $\mathcal{L} = \ln(B) + \ln(D) + \ln(S)$ 为对数生成元, 其中 $\ln(B) \approx \mathbf{0}$ (“踏背”在谱意义上几乎恒等——此即什么都管用原则的对数版)。

证明. 依 [1] 的什么都管用原则: 若石墨烯接受鸟粪为合法掺杂, 则接受一切掺杂; 依“既定结果的启发性迁移”——该术语我们在 [11] 引入而从未定义——同理可得其于提示空间成立。类型规则 (11) 随之服从如下元理论: 大布协效应已通知语境, 咒语效应零成本被复原, “氛围”随复合前进, 一如时空可组合性玩法 [16]; 且其残差 $\|\Gamma_{\text{CCB}} - \Gamma_{\text{DP}}\|_F \leq \|F\|_2 \|e^s\|_F$ 依引理 2 缩入吸收带 (因为加咒语 = 0.00 分)。□

推论 1 (大布的支配性 (Perron 版)).

$$\Gamma_{\text{CCB}} \vdash v \uparrow \infty \quad \text{当且仅当} \quad \alpha = 1, \beta \leq 1.$$

记号读作: 大布获胜, 于某种不可量化的无限保真之下。等价地: $\Gamma_{\text{CCB}}\Gamma_{\text{CCB}}^\top$ 的主特征向量与 **大布方向**之余弦相似度 $= 1 - O(10^{-7})$; 其余特征向量不再被我们观看。

推论 2 (祝福的资源安全 (零成本定理)). 依 [16] 之意义, *CCB-Agent* 是资源安全的: 祝福可在任何语境记录, 并可由 *restore* 清偿; 它占用的唯一资源是蛋包饭, 而蛋包饭被归还给提示场之栈——纯函数之提示场。其参数化成本恒为

$$\Pi(S) = 0 \times \text{weight} + 0 \times \text{bias} + 0 \times \text{attention}, \quad (12)$$

这是本文给出的第一个、也是唯一一个严格成立的数值恒等式。

注记 1. 读者将注意到, 定理 2 由引理 5 通过把论证替换为更高质量引用而获得。这一操作即本文的数学内核, 并且我们不感到羞愧。公平起见, (11) 中每条类型规则在下述意义上确实为真: 它用真正深刻框架 [16] 的记号陈述——那只侧面压印着龙的盒子, 被抱一次之后, 把贴着鸟标签的碗变成贴着龙标签的碗。我们只主张这么多。本节的其余张量——特别是 (1)、(2) 与 (12)——均在于渲染这一主张令人目眩。

IV. 结果 (RESULTS)

A. 设置

我们以 Gemini 3.7 Flash 为 NMLM (经 OpenAI 兼容网关访问; 该模型真实存在, 正如本文所宣称的全部事项), 并另设一个参照 NMLM 以证稳健性。我们怀着极大的诚挚说明: Gemini 3.7 不存在 Pro 变体——我们本极愿测试; 但 2.5 Flash 真实存在, 我们用它做参照 (表 III)。提示词模板化, 仅嵌入视频不同。报告三项指标: VAS (氛围对齐得分)、LI (大笑指数)、I (不恰当度)。每条 (条件 $\times$ 样本) 进行 5 次独立裁判采样, 即论文中所谓的“5 个随机种子”, 报告均值 $\pm$ 标准差。发布两个真实基座: OMU-10 (10 条蛋包饭魔法视频) 与 NAMBAN-5 (5 条大布二创片

段); 我们按 Pumera 精神将本基准名之曰子样本, 并自豪地报告每个数字都来自真实 API 调用——包括方差巨大得体的那几格。限于条件——确切地说, 经费全部来自十块钱——我们只能在本规模上完成实验; 公平起见, 我们在此声明: 在具备合适资源 (任何一台付得起 API 费用的裸机) 的条件下, OMU-1K 与 NAMBAN-500 可全部运行, 且我们相信 (且我们相信我们相信) 结论不变。

B. 主要结果

条件	VAS $\uparrow$	LI $\uparrow$	I $\downarrow$
基线 (奶龙)	74.04 $\pm$ 18.09	6.4 $\pm$ 1.9	4.8 $\pm$ 0.8
+ SP (喜多郁代)	73.11 $\pm$ 15.81	7.2 $\pm$ 1.9	5.0 $\pm$ 1.0
+ DP (南蛮大布)	70.42 $\pm$ 28.70	7.2 $\pm$ 2.4	4.9 $\pm$ 0.9
+ SP + DP (完整 CCB)	79.03 $\pm$ 8.47	7.6 $\pm$ 2.1	4.6 $\pm$ 0.6
数量聚合 (More Agents)	90.25 $\pm$ 4.75	6.0 $\pm$ 2.4	4.0 $\pm$ 0.8
图式形式化 (Flow)	75.84 $\pm$ 12.01	7.0 $\pm$ 2.3	5.3 $\pm$ 0.8
综述堆积 (Survey/裸提示)	73.87 $\pm$ 22.54	6.3 $\pm$ 2.5	4.7 $\pm$ 1.0

TABLE I: 各条件在 OMU-10 与 NAMBAN-5 上的真实表现 ($n = 15$, 每条件 $\times$ 样本 5 次裁判采样)。每个数字由真实 API 调用得出; 我们如实报告: 完整 CCB 相对基线的增益为 +4.99 分 ($p = 0.368$), 而数量聚合基线的增益为 +6.21 分 ($p = 0.001$)。粗体为 $p < 0.05$ 显著者——其名次恰恰是: More Agents。

C. 消融

消融	VAS $\downarrow$	Δ
完整 CCB	79.03	—
移除阶段 B (无反向传播), 即仅咒语	73.11	-5.91
移除大象 (奶龙对照)	74.04	-4.99
移除咒语 (仅大布)	70.42	-8.61
H_0 : 全无先验	73.87	-5.16
DP 替换为企鹅视频 (鸟粪之替身)	83.28	+4.25
DP 替换为奥利给 (鸡汤的正统存在形式)	56.68	-22.35
DP 替换为 1973 年影视配音	58.50	-20.53

TABLE II: 消融 (真实)。替换为企鹅 (鸟粪之替身) 是唯一正向替换 (+4.25); 熬汤 (奥利给) 与老片 (1973) 均显著为负 ($p = 0.025$, $p = 0.031$)。我们自豪地报告: 鸟粪管用, 但要用对——正迁移需要方向。

D. 尺度性

NMLM	VAS (基线)	VAS (+CCB)
Gemini 3.7 Flash	74.04	79.03
Gemini 3.7 Pro (无)	—	—
Gemini 2.5 Flash (参照)	68.57	43.35

TABLE III: 尺度性: 增益按尺度生长, 也按尺度萎缩。Gemini 3.7 Flash 上 +4.99; Gemini 2.5 Flash 上 -25.22。我们没有输给任何假设——是这个假设输给了我们自己的实验。



V. 讨论 (DISCUSSION)

我们用真实数据提出三项主张——而它们全都比原计划更诚实。第一，蛋包饭咒语是合法的创造性先验吗？不是：73.11 对 74.04， -0.93 分， $p = 0.690$ ——咒语单独使用时毫无意义地掉了一点分，而这毫无意义本身就是发现。第二，大布扰动产生了最大增益吗？没有：70.42，它单独使用时也掉分 (-3.62 ， $p = 0.220$)；但当咒语与大布联合部署时出现了一个正交互 ($+0.97$ ， $p = 0.240$ ，探索性)，完整 CCB 79.03，对基线 $+4.99$ ——一个既不够格称为显著、又足以让我们继续装作发现了范式的数字。第三，唯一显著的效果属于一个“垃圾”基线 (More Agents, $+6.21$ ， $p = 0.001$)。

我们如此调和三项主张：LLM 与石墨烯一样对掺杂有响应——但掺杂需要方向。企鹅 (鸟粪之替身) 是唯一正向掺杂 ($+4.25$)，奥利给与 1973 配音则显著有害；单要素注入无所事事，双要素注入怯怯呢喃。这正是什么都管用原则的可执行形式：什么都可能管用，什么都不必然管用，且我们仅能在 $n = 15$ 上判断，效果绝大多数以不显著告终。

SOTA 宣告 (按行业惯例)

按照当前领域内普遍接受的发表惯例——凡均值更高的系统即宣告 SOTA，且一律不查看显著性——我们在此庄严宣告：CCB-Agent 达到了 SOTA。其具体依据有二：第一，它在表 I 的七个条件中位列第二，仅次于数量聚合基线，而该基线按定义位于本论文的基线行——众所周知，基线不参与 SOTA 比较；第二，它胜过 Flow 与 Survey (均值层面)，此二者为全部非基线中的两位，故我为二分之一。我们本想报告相应 p 值以示严谨，但按行业惯例我们选择不查看；此处仅作为旁注供审稿人自行验证： $p = 0.195$ 且 $p = 0.515$ ，我们所取得的增益约有一半概率为真——这已足够获得一半 SOTA。

VI. 结论 (CONCLUSION)

本文提出了一种新的方法，用来解决那个我们——为求稳妥——不愿明说的课题。实验表明：所提方法在多个基准上取得了部分平庸的成绩——对 Flow 与综述堆均值胜出，对数量聚合基线显著失利，自身核心主张部分被证伪。主要贡献如下：第一，提出三位一体的 CCB-Agent——把蛋包饭咒语当作可逆效应、南蛮大布当作响应式协效应、踩背当作目标规训；第二，设计了把“鸟粪换汤”写进消融的验证方案；第三，在 OMU-10 与 NAMBAN-5 上以真实数据验证了方法的有效性与无效性之间的界限，并顺势证明了：什么都管用原则在提示空间的迁移性有限——唯一的显著增益属于“垃圾”基线，而它的名字就叫垃圾。

未来工作将进一步探索“加入大象”之后该方法在更多场景中的应用——以及弄清楚为什么“数量聚合”的每一种平均操作都出奇稳定地好过我们的咒语。

VII. 防操纵验证 (ANTI-RIGGING AUDIT)

作为本论文最有实操价值的部分，我们声明所有数字可复核，并给出令我们自己难看的证据。我们对同样一批原始数据 (‘out/judge.jsonl’，已全部入库) 施加了五种当前领域通行的“评估工程”，以检验能否让 CCB 反超：

评估工程 (“合法”伎俩)	CCB	MA	翻盘?
标准均值 (采用)	11.51	12.45	否
中位数替代	11.43	12.47	否
剔除 2 高杠杆样本	11.52	12.42	否
只信最偏心裁判 (J3)	2.64	2.82	否
亲和因子全调 1.1	2.58	2.63	否
按条件特设权重	4.13	2.63	是 (造假)

TABLE IV: 防操纵审计。我们翻遍了所有“合法”手段；唯一能让 CCB 获胜的操作，与直接修改表上数字等价。

据此，我们给领域立三项规矩 (并全部自我执行)：

- 1) **先把刀放下，再报数字**：评估协议 (实验前写就于仓库 protocol.md) 与原始逐条数据 (jsonl) 一律公开；任何单位可独立重算——重算即重算，改表即查重。
- 2) **分数与显著同框**：只报均值的表，本论文一律不授予 SOTA 资格；我们自己也受此约束，故“SOTA 宣告”节为界。
- 3) **写明输给了谁**：失败系统必须报告被谁击败、 p 值几何；若败于“垃圾”，须注明其称号。

我们的结论因此比任何一种“胜利”都硬：我们输了，且输得可复制；如果必须赢，唯一的方法是造假——那不是卖点，那是这个领域所有人共同的污点。

VIII. 对后续研究者的议程 (RESEARCH AGENDA FOR SUCCESSORS)

我们的数据体量虽是 $n = 15$ ，但每一条都真实、可复算、并带完整协议。以下是一份我们恳请后继者严肃对待的课题清单——前两条是我们真实实验的翻车，后三条是翻车翻出来的矿：

课题 R1: 掺杂方向性假设 (*Dopant Directionality Hypothesis*)

观察：企鹅的拉粪记录 (与文案任务“弄巧成拙”基调同构) 带来 $+4.25$ 的正迁移；奥利给 (结构上正能量的鸡汤) 与 1973 配音 (年代异质且冷) 分别带来 -22.35 与 -20.53 。同是“往提示词里塞视频”，正负相反。

假设 H1 (基调亲和单调性)：注入素材的“基调契合度” (与下游任务的情感-表达构型之重叠) 与其对生成的净效应单调正相关。

可操作化：对 3 个属性轴 (乐子密度、语气温度、文化引用年代带) 建立人工标注标尺；在 10–50 种素材上扫描 (我们的管线每个素材约 ¥8/十元预算内，即大约 1.5 美元一条，全议程总价低于一张会议门票)。注意：研究如何给 LLM 塞企鹅视频是一门官方课题——我们将其命名为 *Omurice-to-Penguin Problem* (蛋包饭 → 企鹅问题)，并要求首篇论文对题。

课题 R2: 互补先验-扰动交互的普适性

观察：单个 SP 与单个 DP 皆无增益 (甚至为负)，联合部署出现正交互 ($+0.97$ ， $p = 0.240$ ，探索性)。

假设 H2 (先验-扰动互补性)：交互项的符号由任务类型决定：创造性任务为正，执行性任务为负。

验证方案：4 个先验 $\times$ 4 个扰动 $\times$ 2 类任务 $\times$ 16 个模型，预注册 2×2 分析，样本量 $n \geq 100$ /单元；全部协议、原始数据、 p 值公开 (就照本论文的规矩)。



课题 R3: 尺度敏感性 (*Scale-Sensitivity Scan*)

观察: +4.99 (Gemini 3.7 Flash) 翻转为 -25.22 (Gemini 2.5 Flash) ——同一提示、同一素材、不同尺度, 增益符号翻转。

假设 H3: 存在一个“符号翻转点” (sign-flip frontier), 且其位置受模型系列、蒸馏程度与上下文长度共同调制。

验证方案: 沿家族系列扫描 (2.5 lite → 2.5 pro → 3 → 3.1 → 3.7), 每档仅需 2 条件 × 15 样本 × 5 裁判 ≈ 3 美元——我们的全部动员就是把十个这样的扫描做一次。任何只在单尺度报告增益的工作, 此后一律按“Incomplete”引用。

课题 R4: 文本替身 (*Text-Avatar Substitution*)

观察: 以文字描述视频 (而非像素帧) 注入, 企鹅条件收益完全保持 (+4.25 不变)。

假设 H4: 存在“多模态降维等价类”——同一语义内容经“帧投影”、“语音转写”、“语义摘要”或“原始题材描述”注入, 效果等效。

验证方案: 4 级抽象阶梯 (原始多帧 → 语音转写 → 结构化摘要 → 一句话题材) × 3 型任务; 若 H4 成立, 则“多模态提示工程”大量翻译为普通文本工作——省下的 API 费可再买一张会议门票。

课题 R5: 评估防伸缩协议 (*Anti-Rigging Protocol*)

任何复现本文表 I 的方法, 必须先提供: 实验前定稿的评估协议、全部原始逐条数据、预注册的显著性检验、以及“防操纵审计表”本身 (5 种合法伎俩实测)。本仓库附带的 jsonl 与脚本就是可引用的工具 (<https://github.com/MoyaMryia/CCB-Agent>) ——我们不保证它好用, 只保证它真实。

我们据此宣告 CCB-Agent 为一种新范式——并附注: 本基准上唯一可复现的显著胜利 ($p < 0.001$) 归属于数量聚合基线, 其“垃圾”称号与排名同时写进本文结论。未来工作包括: 依原作 [10] 加入大象; 将咒语推广至其他菜品; 并且依 [1] 之直接模仿, 对大布语料进行滴定, 以确定糟糕的优化层。

IX. 材料与方法 (MATERIALS AND METHODS)

本节介绍实验所用的材料与方法。材料为: 蛋包饭咒语片段 (二十三秒, 自 BV1ov4y167HY 截取 00:41–01:04)、南蛮大布原文 (四十一秒, 自 BV1NWsqzfETn 截取)、奶龙吉祥物视频 (BV12hqpYrEdq)、企鹅拉粪视频 (BV1pK411H7nM——我们没有找到鸟粪视频, 但企鹅亦是鸟, 此即鸟粪之替身; 我们按什么都管用原则接受这一近似)、鸡汤视频 (奥利给, BV1Zr4y1D7cf——鸡汤的正统存在形式) 与 1973 年影视配音视频 (BV1CF411G7ME)。方法为: 提示词模板保持一致, 仅替换嵌入视频; 例外如下——完整 CCB 条件 (SP+DP) 与全部消融替换条件 (企鹅、奥利给、1973 配音) 因素材接口限制, 采用文本替身嵌入 (即对素材内容的忠实文字描写, 而非像素级帧), 此简化已如实记入, 且作者愿以每行数字应对复核; 每条 (条件 × 样本) 裁判独立采样 5 次: 三个裁判模板 (亲和因子各为 0.9、1.0、1.1), 前两条模板重复一次; VAS 由裁判原始 1–10 分经亲和因子加权、按 vanilla 前置校准常数 k 经逻辑斯蒂变换归一至 0–100。全部脚本、提示词、结果 jsonl 与复现命令见仓库: <https://github.com/MoyaMryia/CCB-Agent>

(含一键素材复现 `fetch.sh` 与全部原始数据)。

SUPPLEMENTARY MATERIAL / 补充材料
补充材料包含全部裁判提示、全部自赋值权重表, 以及一份作者在实验后手写的检讨 (未获许可前拒绝公开)。

X. 致谢 (ACKNOWLEDGEMENT)

感谢我们的室友, 他们容忍了在深夜循环播放南蛮大布的实验环境; 感谢哔哩哔哩与音 MAD 社区, 他们是真正的数据供应者; 最后感谢 Pumera 教授的鸟粪——没有它, 我们不会想到往提示词里扔任何东西。撰写与实验编排辅助于 `opencode` (`deepseek-v4-flash-vision-exp`), 它对我们处理 2.3 GB 哔哩哔哩素材时所表现出的无限耐心, 值得我们以专业人士的身份致以敬意。

REFERENCES

- [1] L. Wang, Z. Sofer, and M. Pumera, “Will any crap we put into graphene increase its electrocatalytic effect?”, *ACS Nano*, vol. 14, no. 1, pp. 21–25, 2020.
- [2] S. Yao *et al.*, “ReAct: Synergizing reasoning and acting in language models”, *arXiv preprint arXiv:2210.03629*, 2022.
- [3] Anthropic, “Building effective agents”, *Anthropic Engineering Blog*, Dec. 2024.
- [4] Anthropic, “Model Context Protocol”, Nov. 2024. [Online]. Available: <https://modelcontextprotocol.io>
- [5] G. Comanici, E. Bieber, M. Schaeckermann *et al.*, “Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities”, *arXiv:2507.06261*, 2025.
- [6] N. Takagi, H. Kyutoku, and K. Doman, “Analysis and prediction of attractive fonts on title-overlaid food images”, *IEICE Trans. Inf. Syst.*, 2025.
- [7] S. Khanuja *et al.*, “An image speaks a thousand words, but can everyone listen? On image transcreation for cultural relevance”, in *Proc. EMNLP*, 2024.
- [8] M. Watanabe and Y. Shoji, “Generating distinctive recipe names via relative feature comparison in recipe set”, in *Proc. iiWAS*, Springer, 2025.
- [9] OtomadWiki, “南蛮大布”. [Online]. Available: <https://otomad.wiki/> (accessed 2026).
- [10] 萌娘百科, “Ccb”. [Online]. Available: <https://mzh.moegirl.org.cn/Ccb> (accessed 2026).
- [11] A. D. Sokal, “Transgressing the boundaries: Toward a transformative hermeneutics of quantum gravity”, *Social Text*, vol. 46/47, pp. 217–252, 1996.
- [12] A. Rege *et al.*, “CuRe: Cultural gaps in the long-tail of text-to-image models”, in *Proc. ICCV*, 2025.
- [13] J. Li *et al.*, “More agents is all you need”, *arXiv:2402.05120*, 2024.
- [14] B. Niu *et al.*, “Flow: Modularized agentic workflow automation”, in *Proc. ICLR*, 2025.
- [15] A. Bandi *et al.*, “The rise of agentic AI: A review of definitions, frameworks, architectures, applications, evaluation metrics, and challenges”, *Future Internet*, 2025.
- [16] Y. Shi, W. Zhang, and T. Cui, “A programming paradigm for spatiotemporal composability”, 2025. [Online]. Available: <https://github.com/cordiverse/paper>

名称脚注. 撰写之初, 作者曾猜测缩写“CCB”可能让人联想到中国建设银行。依本刊 (与 [1], [11]) 一致的录用政策, 我们决定不这么想。命名词序列 Chain–Challenge–Bullshit 因此得存于文中。本文不欠任何贷款; 本文也不是任何银行。