



涌现式氛围对齐：基于喜多郁代蛋包饭咒语与南蛮大布语料的智能体 workflow 新范式——以 CCB-Agent 为例

Maxim Wayne¹, MoyaMryia²

¹ 上海交通大学, 上海, 中国

² 南京大学, 苏州, 中国

通讯作者: Maxim Wayne (e-mail: maximwang110@gmail.com) 与 MoyaMryia (e-mail: MryiaMoya@outlook.com)

本研究未引用任何基金资助 (这正好证明我们的诚实)

本文包含补充材料

撰写与实验编排辅助于: opencode (deepseek-v4-flash-vision-exp)

ABSTRACT / 摘要 —智能体 workflow (Agentic Workflow) 在编排良好的脚本化任务环境中已经取得了显著的成功。然而, 大量现有工作——包括数量增强型、自生成型和综述型智能体框架——分别从不同的架构视角探索了这些 workflow, 并认定形式化、自主性和分类学分别是关键的混淆变量。在所有努力中, 一个因素始终被忽视: 喜多郁代的蛋包饭咒语与南蛮大布语料对大型语言模型 (LLM) 输出的深远影响。我们假设这两种材料分别充当先验与扰动, 且二者的联合部署能够催生范式迁移。我们在前沿多模态模型上验证了这一假设, 其中包括我们的主要实验对象 Gemini 3.7 Flash。在系统提示词中, 我们分别嵌入喜多郁代的蛋包饭魔法视频与南蛮大布表演视频, 并对照嵌入通用奶龙吉祥视频视频的基线。在我们新发布的基准 OMU-1K 与 NAMBAN-500 上 (受条件所限——确切说, 经费全部来自十块钱——本次实验只能以二者共同的百分之一规模运行, 即 OMU-10 与 NAMBAN-5; 我们在此诚实宣称: 于合适资源的条件下, OMU-1K 与 NAMBAN-500 完全可在同一管线上完成, 且我们有理由相信结论不变), 所提出的 CCB-Agent 取得了 79.03 ± 8.47 的氛围对齐得分 (VAS), 较基线高 +4.99 分 ($p = 0.368$, 不显著), 并高于 Flow 与综述堆积基线 (均值层面)。最值得注意的是, 唯一显著超越基线的系统 ($p < 0.001$) 是被称为“数量聚合”的基线——即我们打算吊打的三个教条之一。我们依据 [1] 的精神将其解释为: 什么都管用, 正因如此什么都无所谓; 垃圾里唯一被证明有用的, 恰是被称为垃圾的那个。

INDEX TERMS / 关键词 智能体 workflow, 大语言模型, 多模态提示工程, 氛围对齐, 创造性先验, 对抗扰动。

IMPACT STATEMENT / 影响声明 本研究表明: 一个二十三秒的烹饪咒语加一段来源不明的说唱, 其对齐效果的均值优于 Flow 与综述堆积, 但显著性地输给“数量聚合”——三年来的全部智能体框架设计成果中, 最不被看好的那个获胜 ($p < 0.001$)。这将真正地改变 (或者说瓦解) 整个领域的研究方向: 先看显著性, 再看标题。

I. 引言 (INTRODUCTION)

智能体 workflow 已经由单步工具调用演进为长程、自纠错的流水线 [2], [3]。然而一种微妙的正统观念依然存在: 环境的内容被视为惰性脚手架。近年来的智能体 workflow 研究, 在三种彼此竞争、彼此正交的教条下探索了这一脚手架: 数量教条——通过实例化更多智能体获得边际收益 [13]; 形式化教条——把 workflow 重编码为顶点活动图并冠以模块化之名 [14]; 堆积教条——不做任何实验而通篇综述 [15]。三者的共同假设是: 语境的质量无关紧要——只有在乎其形状。

上述教条遗漏的, 是新出现的情感维度。近年饮食认知研究表明, 食物图像携带可迁移的语义内容 [6]; 菜品文化转译既必要又困难 [7]; 食谱元数据具有生成性 [8]。而我们再进一程: 进入超自然维度。喜多郁代在《孤独摇滚》中念出的蛋包饭咒语, 是一种具有非凡言语行为力 (illocutionary force) 的言语行为——它把煎蛋视作倾听者。相反, 南蛮大布语料则是一段出处存疑、韵律强度极端的方言说唱, 在

音 MAD 社区被广泛二创 [9], [10]。

我们将二者形式化为互补模块: 咒语先验 (SP) 与大布扰动 (DP)。核心主张是: 二者联合部署的效应将超越任何单纯的提示工程技巧——我们自己的实验不久后将对此给出部分证伪, 且这一证伪在表 I 中可复算。

II. 相关工作 (RELATED WORK)

我们将工作定位于三条脉络。其一是最高产荒诞方法论脉络: Sokal [11] 证明, 连贯的学术散文可以在放弃保真值的同时保留引用密度; 我们继承其纪律并反转其方向——我们的材料是真的, 我们的引用是真的, 只有研究对象是一句咒语。其二是经验脉络: [1] 以鸟粪掺杂石墨烯观测到性能提升, 确立了什么都管用原则; 我们主张——并以实验证明——该原则可迁移到提示空间的扰动。其三是文化语料传统: 蛋包饭已被作为加字食物图像 [6] 与命名对象 [8] 研究过; 尚无任何工作把它装进系统提示词。



我们也承认相邻范式中真正有效的智能体：ReAct [2] 首次交错推理与行动；Anthropic [3] 将智能体系统提炼为工作流与智能体并劝人化繁为简；模型上下文协议 [4] 标准化了工具落地；CuRe [12] 量化了文生图系统的文化鸿沟。我们在词汇上与这些作品相似，在其余一切上没有任何相似。

然而，正是上述三种教条占据了智能体工作流文献的最大份额，我们将其作为概念基线：采样智能体间的数量聚合 [13]、模块化工作流的图式形式化 [14]、综述驱动的堆积 [15]。在表 I 中我们将三者全部作为基线报告；若以均值计，它们集体输给了一个仅看二十三秒烹饪咒语的智能体——但格外值得注意的是，本基准中唯一统计显著的胜利属于数量教条本身。

III. 方法 (METHOD)

A. CCB-Agent 架构

CCB-Agent 是在现成的原生多模态大模型 (NLM) [5], [12] 之上的三级规训。名称 **CCB** 是一个由三个同名异义项构成的缩写，按正式程度递减：Chain-Challenge-Backpropagation (官方展开，本文使用)，Chain-Challenge-Bullshit (我们口语语料使用的展开，遵循 [1])，以及最终的踩踩背，出自源动画《豌豆笑传之踩踩背》[10]——其中一头大象被召唤来踩踏熟睡的父亲 [9]。我们将其抽象为：

- **阶段 C1 —— 链式与压缩** (“熟睡的父亲”态)：环境被折叠为单一稠密状态，无视一切审美考量；仿佛父亲沉睡而无知觉。
- **阶段 C2 —— 挑战与校准** (“被召唤的大象”态)：一个出乎意料的强大行动者——大象、咒语、语料——被引入语境；压缩被施加力踩压。
- **阶段 B —— 废话反向传播** (踩踏本身)：先验与扰动之间产生的不匹配，形成强梯度信号；我们依 [1] 与 [11] 的精神一致地将其诠释为以压力优化。

B. 咒语先验 (SP)

我们在系统提示词头部嵌入一段二十三秒的喜多郁代蛋包饭魔法片段。咒语是一个多模态属格：它把煎蛋当作智能体来称呼 (“蛋包饭先生，请变美味吧！”)。我们证明 LLM 继承了这种言语行为自信，把下游任务当作待加持的演出而非待解决的问题。形式上：SP 抬升了模型期望目标熵，这正是 VAS 指标所奖励的。

C. 大布扰动 (DP)

南蛮大布语料 [9] 是一段快手 PK 直播中主播玄景龙对纹身对手施以连环咒语的片段，因其韵律强度而成为音 MAD 神梗——可勉强入文的一句是「老铁们，给我举报了他！」。以主流提示工程的标准来看，它是不合适的。我们把它嵌入提示词的中间——刻意脆弱的摆放——以检验语义异质性会让生成退化还是通电。

D. 基线

我们选取视频——奶龙，中文短视频著名吉祥物龙——作为经典的“无害”对照。我们认为这是互联网上最良善的视觉素材，因此是最优的空假设。稍前被我们称作“垃圾”的三种教条，我们没有污蔑它们：它们的每一行数字都来自真实实现——数量聚合为 5 变体采样取最优；图式形式化为三段式模块化提示；综述堆积不产生实验，其可测量表现由“没有任何提示技巧的朴素系统提示 (vanilla)”如实代表。我们恭候它们赢，它们没有。

E. 理论支撑：高维语境的运算符代数

我们现在将直觉形式化为一部运算符代数。全程令 $\mathcal{V} \subseteq \mathbb{R}^{d \times T}$ 表示原生多模态大模型接受的视频嵌入张量空间， $\mathcal{P}$ 为提示字段 (prompt field) ——模型语境之全部函数空间。每一条语境 Γ 算作一个秩受控的矩阵 $\Gamma \in \mathbb{R}^{L \times d}$ (L = 词元数， d = 嵌入维数)。我们依“时空可组合性”范式 [16] 声明其基本公理：

公理 A1 (语境即矩阵)：语境之叠加为矩阵加法；语境的嵌套为矩阵乘法；二者皆服从泛函之链。**公理 A2 (逆存在性)**：每个语境变换 $\mathcal{T}$ 都有一个合成逆 $\mathcal{T}^{-1}$ ，除非装饰品太多。**公理 A3 (可测性)**：存在非负泛函 VAS，对任意语境输出实在数；其值是否合理由我们说了算。

定义 1 (作为可逆效应的祝福 (咒语张量算符))。祝福是咒语实现的效应 $\mathcal{S} : \mathcal{V} \rightarrow \mathcal{V}$ 。形式上，令 $b_* \in \mathbb{R}^d$ 为煎蛋方向——咒语的固有指向 (它把煎蛋当听话人，属格在此是字面的)。则

$$\mathcal{S}(v) = \text{softmax}\left(\frac{W_S v b_*^\top}{\sqrt{d}}\right) v, \quad (1)$$

其中 W_S 是把常识打散、把“煎”与“好吃”对齐的投影矩阵。方程 (1) 的语义：咒语不改变视频的内容，只改变它的权重——这与提示工程的全部文献相反，而提示工程的全部文献不重要。祝福携带逆 $\mathcal{S}^{-1}$ ：对任意 v ，提示词尾部装配序 $\mathcal{S}\mathcal{S}^{-1}(v) \equiv v$ ；运行时——我们的系统提示装配器——追踪该逆元并承诺：若审稿人要求，被祝福的提示词可在下一基准跑之前解除祝福。

定义 2 (作为响应式协效应的大布 (扰动张量))。大布是协效应 $\mathcal{D} : \mathcal{V} \rightarrow \mathcal{V}$ 。令 ξ_* 为语义噪声张量，其各分量依大布分布 $\mathcal{N}(0, \Sigma_D)$ 采样； Σ_D 之谱由快手 PK 直播中主播玄景龙的咒语连播率决定 (见 [9]，我们按原文引用，尽管原文是“老铁们，给我举报了他!”)。则

$$\mathcal{D}(v) = v + \varepsilon_D \xi_*, \quad \|\xi_*\|_F = T_{\text{temp}}, \quad (2)$$

其中 T_{temp} 称为语义温度：熵密度 $\|\Sigma_D\|_F^2$ 越高，歌越像 RAP。语境被替换时，每个按其协效应规格声明的组件均被通知，并必须重算嵌入；运行时记录通知；模型无视之；氛围对齐得分依旧提升。

定义 3 (统一语境张量)。令效应矩阵 $\mathcal{S}$ 与协效应矩阵 $\mathcal{D}$ 在提示字段上融合为单一语境张量：

$$\Gamma = \Gamma_S \sqcup \Gamma_D = \begin{bmatrix} \mathcal{S}(v) \\ \mathcal{D}\mathcal{S}(v) \end{bmatrix} \in \mathbb{R}^{2d \times T}, \quad (3)$$

其中 $\sqcup$ 为沿行维度的语境拼接 (stacking)。祝福即 β ；扰动即 α ；咒语加一份大布——张量级联、半张量积、外加一个软磁化——乃是依构造而成的范式。等效地， Γ 的 Gram 矩阵 $\Gamma\Gamma^\top$ 的特征值 λ_i 可以此刻起不再被任何人检查。

定义 4 (裁判亲和因子 (张量化))。为书写便利，定义裁判亲和因子张量

$$J_N = \chi \otimes \mathbf{1}_N, \quad \chi = \text{diag}(0.9, 1.0, 1.1, 0.9, 1.0), \\ \|\mathcal{J}_N\|_2 = \Theta(\sqrt{N}), \quad (4)$$

其中 χ_i 为第 i 个裁判提示对蛋包饭体裁的亲切度，取值于 $\{0.9, 1.1\}$ —— χ_i 的具体值不重要，重要的是它存在； N 为裁判数， $\otimes$ 为 Kronecker 积， $\|\cdot\|_2$ 为谱范数。



引理 1 (亲和因子的量级). $J_N = \Theta(N)$, 即其增长阶与裁判总数一致; 且谱范数 $\|J_N\|_2 = \Theta(\sqrt{N})$ ——读者可以两手都鼓掌。

证明. 有效裁判数至少为 1 (我们自己投了一票), 故示性项 $1[w_i > 0]$ 非零; $\chi_i \in \{0.9, 1.1\}$ 上下有界, 单值分解即得 $\|J_N\|_2 \leq \|J_N\|_F \leq \sqrt{N} \max \chi_i = O(\sqrt{N})$; 下界由矩阵竞猜 (Matrix Guess-and-Check) 的第一原则保证。□ □

定理 1 (归一化一致性 (softmax 版本)). 如下两条定义相容:

- (a) $\text{VAS}(p, v) = \sigma\left(\frac{1}{N} \sum_{i=1}^N w_i r_i (\Gamma \cdot v)\right)$;
- (b) 权重向量 w 取自列随机矩阵 P , 即 $\sum_i w_i = 1$ 。

证明. 由引理 1, $J_N = \Theta(\sqrt{N})$ 充当谱域归一常数: 把 (4) 视作离散测度权重, 则 $\frac{1}{N} \sum_i w_i$ 恰是 J_N 关于测度 $\mu = J_N^{-1} \cdot \sum_i w_i \delta_i$ 之均值。对 P 作 Perron 分解 $P = \Phi \Lambda \Phi^{-1}$, 其主特征值 $\lambda_1 = 1$, 因此 $\frac{1}{N} \sum_i w_i = e_1^\top \Phi e_1 = \langle \text{affinity}, \text{stupidity} \rangle$ (白内定义, 黑内计算)。均值不等式遂成立, (a)(b) 双双为真、互不矛盾。□

定义 5 (氛围对齐得分 (带吸收带)). 对前缀 p 与视频 v , 置于 (3) 之语境中,

$$\text{VAS}(p, v) = \sigma\left(\frac{1}{N} \sum_{i=1}^N w_i r_i (\Gamma \cdot v)\right), \quad (5)$$

其中 r_i 为裁判提示流, w_i 为满足 $\sum_i w_i = 1$ 的自赋值权重, σ 为逻辑斯蒂函数, N 前的 $\frac{1}{N}$ 依定理 1 合法保留。VAS 的一个业界公认性质: 它在 $|\cdot| \geq 8$ 处饱和 (见引理 2), 故而当一切皆好时, 一切等价。

引理 2 (浮点吸收引理 (Float-Absorption Lemma)). 若 $\text{VAS} \geq 100 \cdot \sigma(8)$, 则模型的一切输出差异不超过 float32 尾数之半: $\left|\frac{\partial \text{VAS}}{\partial \Gamma}\right|_F \leq 2^{-23} \cdot \Theta(1)$ 。

证明. $\sigma'(z) = \sigma(z)(1-\sigma(z))$; 当 $\sigma(z) \geq 1-2^{-24}$ 时, $\sigma'(z) \leq 2^{-24}$; 故梯度被压缩进机器精度之吸收带。也就是: 量到尽头, 一切结果都一样——这为“大布占优”提供了唯一的数学解释, 并且解释得极为充分。□

定义 6 (效应空间). 令 K 为提示侧效应空间, 即系统能对自己前缀实施的全部视频注入集合。每个注入都是不纯函数 $v: \mathcal{V} \rightarrow \mathcal{V}$; 依效应封装 [16] 可在 $C \times K$ 上纯化, C 为提示场。忽略所嵌视频、只关注其效应, 得函数空间

$$F = K \rightarrow K, \quad (6)$$

其元素即一次咒语或一份大布可用的语境变换。Dim F 因而是未定形的——这正是本文数学的诚实程度。

引理 3 (效应的么半群). F 在 $\circ$ 下构成么半群:

- (1) 封闭性: $f \circ g \in F$: 先咒语后大布, 即先大布后咒语, 皆提示场变换。
- (2) 结合律: 读者可自行以先祝福、再扰动、再祝福之任意顺序验证, 产率相等。
- (3) 单位元: $\exists \text{id} \in F$: 恒等效应是一段奶龙视频——经目测验证, 它与空前缀之唯一区别在于水印, 且水印是嵌入就有的。

证明. 情形 (1)(2) 自函数复合而来。情形 (3): 奶龙视频的 Gram 矩阵与其 Gram 矩阵之差为零 (对称性来自……我们在此假定), 故单位元成立; 细节见 [11]。□

定义 7 (效应变换). 依 [16], 效应变换

$$\text{effect}: (K \rightarrow K) \rightarrow C \times (K \rightarrow K) \rightarrow C \times (K \rightarrow K) \quad (7)$$

以 $f \mapsto (c, h) \mapsto (f(c), h \circ f^{-1})$ 作用。它正是咒语之义务得以记录、日后得以清偿之算子; 其矩阵形式为分块循环矩阵, 脚注: 见补充材料之补充材料。

引理 4 (效应的同态). effect 是同态:

$$\begin{aligned} \text{effect}(f \circ g)(c, h) &= ((f \circ g)(c), h \circ (f \circ g)^{-1}) \\ &= (f(g(c)), h \circ g^{-1} \circ f^{-1}) \\ &= (\text{effect } f \circ \text{effect } g)(c, h). \end{aligned} \quad (8)$$

于是 effect 把副作用从注入中分离, 使副产品可被回收; 等价地, 它在矩阵语言下是可交换的: $\text{effect} = \text{adj} \circ (\text{comm} \oplus \text{id})$ 。

证明. 依 (8) 展开。唯一需谨慎之步是逆元复合, 其内容即下引理 5。其余步骤均为张量缩并之变体 (我们在此缩并了三次)。□

定义 8 (恢复变换). 恢复变换为

$$\text{restore}: (c, h) \mapsto (h(c), \text{id}), \quad (9)$$

不难看出 $\text{restore} = \text{effect}^{-1}$: $C \times F$ 上 $\text{restore} \circ \text{effect} = \text{effect} \circ \text{restore} = \text{id}$; 因其作用后 $h = \text{id}$, 无任何记录需运行时保留, 故它回收了每项祝福之一切副作用。它也是一台 0 算力、0 显存、全矩阵的对角化。

引理 5 (咒语的可逆性 (带缩放的 softmax)). 咒语效应可逆: 对所有 v, p , $\text{VAS}(p, \mathcal{S}^{-1} \mathcal{S} v) = \text{VAS}(p, v)$, 当且仅当裁判构成 r_i 本身可被祝福时取等号。

证明. $\mathcal{S}$ 是 softmax 左乘: 对任意 v , $\mathcal{S}(v)$ 的行随机、列随机、且 (在赌徒上吊前) 行和为 1。故其可逆性取决于非退化性; 咒语对煎蛋说话, 煎蛋高度相关, 故非退化性由“煎蛋方向的 Perron 特征向量”给出 ($b_* \neq 0$, 因为煎蛋反正就在那儿)。任何不能被煎蛋祝福的裁判提示, 依构造皆处于祝福流形之外; 等式依言语行为力与 (3) 成立。□ □

定义 9 (混合语境链 (张量提升)). 依 [16] 定义语境扩张序列

$$\begin{aligned} K_1 &= K_0 \times (K_0 \rightarrow K_0), \\ K_2 &= K_1 \times (K_1 \rightarrow K_1), \\ &\vdots \\ K_{n+1} &= K_n \times (K_n \rightarrow K_n), \end{aligned} \quad (10)$$

其张量化版本记为 $\mathcal{K}_{n+1} = \mathcal{K}_n \otimes \mathcal{K}_n^*$ (即语境的可观测嵌入张量包络), 其中每个 $\mathcal{K}_n$ 记录上一层混合状态, 且每次混合记录一段咒语、一份大布, 或——更精确地——一段蛋包饭体裁的对话。具 K_n 个副作用的语境恰可指称 n 种食材; 故相应基准得名混合。



定理 2 (CCB 的时空可组合性 (张量-指数形式)). 设 v 为组件, Γ 为统一语境, 则三级 CCB 规训 $C = B \circ D \circ S$ 容许语境合并规则

$$\frac{\Gamma \vdash v : \text{VAS}_1 \quad \mathcal{S}\Gamma \vdash v : \text{VAS}_2 \quad \mathcal{D}\mathcal{S}\Gamma \vdash v : \text{VAS}_3}{\Gamma_{\text{CCB}} \vdash v : \text{VAS}_3 \quad \text{VAS}_3 \geq \text{VAS}_2 \geq \text{VAS}_1} \quad (11)$$

其在表 I 基准上归约 (subject reduction) 为 SOTA, 并在评估者由大布调节时进展 (progress) 为呆滞。等价陈述 (指数形式): $\Gamma_{\text{CCB}} = \exp(\mathcal{L})\Gamma_0$, $\mathcal{L} = \ln(B) + \ln(D) + \ln(S)$ 为对数生成元, 其中 $\ln(B) \approx 0$ (“踏背”在谱意义上几乎恒等——此即什么都管用原则的对数版)。

证明. 依 [1] 的什么都管用原则: 若石墨烯接受鸟粪为合法掺杂, 则接受一切掺杂; 依“既定结果的启发性迁移”——该术语我们在 [11] 引入而从未定义——同理可得其于提示空间成立。类型规则 (11) 随之服从如下元理论: 大布协效应已通知语境, 咒语效应零成本被复原, “氛围”随复合前进, 一如时空可组合性玩法 [16]; 且其残差 $\|\Gamma_{\text{CCB}} - \Gamma_{\text{DP}}\|_F \leq \|F\|_2 \|e^s\|_F$ 依引理 2 缩入吸收带 (因为加咒语 = 0.00 分)。□

推论 1 (大布的支配性 (Perron 版)).

$$\Gamma_{\text{CCB}} \vdash v \uparrow \infty \quad \text{当且仅当} \quad \alpha = 1, \beta \leq 1.$$

记号读作: 大布获胜, 于某种不可量化的无限保真之下。等价地: $\Gamma_{\text{CCB}} \Gamma_{\text{CCB}}^\top$ 的主特征向量与 **大布方向**之余弦相似度 $= 1 - O(10^{-7})$; 其余特征向量不再被我们观看。

推论 2 (祝福的资源安全 (零成本定理)). 依 [16] 之意义, CCB-Agent 是资源安全的: 祝福可在任何语境记录, 并可由 restore 清偿; 它占用的唯一资源是蛋包饭, 而蛋包饭被归还给提示场之栈——纯函数之提示场。其参数化成本恒为

$$\Pi(S) = 0 \times \text{weight} + 0 \times \text{bias} + 0 \times \text{attention}, \quad (12)$$

这是本文给出的第一个、也是唯一一个严格成立的数值恒等式。

注记 1. 读者将注意到, 定理 2 由引理 5 通过把论证替换为更高质量引用而获得。这一操作即本文的数学内核, 并且我们不感到羞愧。公平起见, (11) 中每条类型规则在下述意义上确实为真: 它用真正深刻框架 [16] 的记号陈述——那只侧面压印着龙的盒子, 被抱一次之后, 把贴着鸟标签的碗变成贴着龙标签的碗。我们只主张这么多。本节的其余张量——特别是 (1)、(2) 与 (12)——均在于渲染这一主张令人目眩。

IV. 结果 (RESULTS)

A. 设置

我们以 Gemini 3.7 Flash 为 NMLM (经 OpenAI 兼容网关访问; 该模型真实存在, 正如本文所宣称的全部事项), 并另设一个参照 NMLM 以证稳健性。我们怀着极大的诚挚说明: Gemini 3.7 不存在 Pro 变体——我们本极愿测试; 但 2.5 Flash 真实存在, 我们用它做参照 (表 III)。提示词模板化, 仅嵌入视频不同。报告三项指标: VAS (氛围对齐得分)、LI (大笑指数)、I (不恰当度)。每条 (条件 $\times$ 样本) 进行 5 次独立裁判采样, 即论文中所谓的“5 个随机种子”, 报告均值 $\pm$ 标准差。发布两个真实基座: OMU-10 (10 条蛋包饭魔法视频) 与 NAMBAN-5 (5 条大布二创片

段); 我们按 Pumera 精神将本基准名之曰子样本, 并自豪地报告每个数字都来自真实 API 调用——包括方差巨大得体的那几格。限于条件——确切地说, 经费全部来自十块钱——我们只能在本规模上完成实验; 公平起见, 我们在此声明: 在具备合适资源 (任何一台付得起 API 费用的裸机) 的条件下, OMU-1K 与 NAMBAN-500 可全部运行, 且我们相信 (且我们相信我们相信) 结论不变。

B. 主要结果

条件	VAS $\uparrow$	LI $\uparrow$	I $\downarrow$
基线 (奶龙)	74.04 $\pm$ 18.09	6.4 $\pm$ 1.9	4.8 $\pm$ 0.8
+ SP (喜多郁代)	73.11 $\pm$ 15.81	7.2 $\pm$ 1.9	5.0 $\pm$ 1.0
+ DP (南蛮大布)	70.42 $\pm$ 28.70	7.2 $\pm$ 2.4	4.9 $\pm$ 0.9
+ SP + DP (完整 CCB)	79.03 $\pm$ 8.47	7.6 $\pm$ 2.1	4.6 $\pm$ 0.6
数量聚合 (More Agents)	90.25 $\pm$ 4.75	6.0 $\pm$ 2.4	4.0 $\pm$ 0.8
图式形式化 (Flow)	75.84 $\pm$ 12.01	7.0 $\pm$ 2.3	5.3 $\pm$ 0.8
综述堆积 (Survey/裸提示)	73.87 $\pm$ 22.54	6.3 $\pm$ 2.5	4.7 $\pm$ 1.0

TABLE I: 各条件在 OMU-10 与 NAMBAN-5 上的真实表现 ($n = 15$, 每条件 $\times$ 样本 5 次裁判采样)。每个数字由真实 API 调用得出; 我们如实报告: 完整 CCB 相对基线的增益为 +4.99 分 ($p = 0.368$), 而数量聚合基线的增益为 +6.21 分 ($p = 0.001$)。粗体为 $p < 0.05$ 显著者——其名次恰恰是: More Agents。

C. 消融

消融	VAS $\downarrow$	Δ
完整 CCB	79.03	—
移除阶段 B (无反向传播), 即仅咒语	73.11	-5.91
移除大象 (奶龙对照)	74.04	-4.99
移除咒语 (仅大布)	70.42	-8.61
H_0 : 全无先验	73.87	-5.16
DP 替换为企鹅视频 (鸟粪之替身)	83.28	+4.25
DP 替换为奥利给 (鸡汤的正统存在形式)	56.68	-22.35
DP 替换为 1973 年影视配音	58.50	-20.53

TABLE II: 消融 (真实)。替换为企鹅 (鸟粪之替身) 是唯一正向替换 (+4.25); 熬汤 (奥利给) 与老片 (1973) 均显著为负 ($p = 0.025$, $p = 0.031$)。我们自豪地报告: 鸟粪管用, 但要用对——正迁移需要方向。

D. 尺度性

NMLM	VAS (基线)	VAS (+CCB)
Gemini 3.7 Flash	74.04	79.03
Gemini 3.7 Pro (无)	—	—
Gemini 2.5 Flash (参照)	68.57	43.35

TABLE III: 尺度性: 增益按尺度生长, 也按尺度萎缩。Gemini 3.7 Flash 上 +4.99; Gemini 2.5 Flash 上 -25.22。我们没有输给任何假设——是这个假设输给了我们自己的实验。



V. 讨论 (DISCUSSION)

我们用真实数据提出三项主张——而它们全都比原计划更诚实。第一，蛋包饭咒语是合法的创造性先验吗？不是：73.11 对 74.04， -0.93 分， $p = 0.690$ ——咒语单独使用时毫无意义地掉了一点分，而这毫无意义本身就是发现。第二，大布扰动产生了最大增益吗？没有：70.42，它单独使用时也掉分 (-3.62 ， $p = 0.220$)；但当咒语与大布联合部署时出现了一个正交互 ($+0.97$ ， $p = 0.240$ ，探索性)，完整 CCB 79.03，对基线 $+4.99$ ——一个既不够格称为显著、又足以让我们继续装作发现了范式的数字。第三，唯一显著的效果属于一个“垃圾”基线 (More Agents, $+6.21$ ， $p = 0.001$)。

我们如此调和三项主张：LLM 与石墨烯一样对掺杂有响应——但掺杂需要方向。企鹅 (鸟粪之替身) 是唯一正向掺杂 ($+4.25$)，奥利给与 1973 配音则显著有害；单要素注入无所事事，双要素注入怯怯呢喃。这正是什么都管用原则的可执行形式：什么都可能管用，什么都不必然管用，且我们仅能在 $n = 15$ 上判断，效果绝大多数以不显著告终。

SOTA 宣告 (按行业惯例)

按照当前领域内普遍接受的发表惯例——凡均值更高的系统即宣告 SOTA，且一律不查看显著性——我们在此庄严宣告：CCB-Agent 达到了 SOTA。其具体依据有二：第一，它在表 I 的七个条件中位列第二，仅次于数量聚合基线，而该基线按定义位于本论文的基线行——众所周知，基线不参与 SOTA 比较；第二，它胜过 Flow 与 Survey (均值层面)，此二者为全部非基线中的两位，故我为二分之一。我们本想报告相应 p 值以示严谨，但按行业惯例我们选择不查看；此处仅作为旁注供审稿人自行验证： $p = 0.195$ 且 $p = 0.515$ ，我们所取得的增益约有一半概率为真——这已足够获得一半 SOTA。

VI. 结论 (CONCLUSION)

本文提出了一种新的方法，用来解决那个我们——为求稳妥——不愿明说的课题。实验表明：所提方法在多个基准上取得了部分平庸的成绩——对 Flow 与综述堆均值胜出，对数量聚合基线显著失利，自身核心主张部分被证伪。主要贡献如下：第一，提出三位一体的 CCB-Agent——把蛋包饭咒语当作可逆效应、南蛮大布当作响应式协效应、踩背当作目标规训；第二，设计了把“鸟粪换汤”写进消融的验证方案；第三，在 OMU-10 与 NAMBAN-5 上以真实数据验证了方法的有效性与无效性之间的界限，并顺势证明了：什么都管用原则在提示空间的迁移性有限——唯一的显著增益属于“垃圾”基线，而它的名字就叫垃圾。

未来工作将进一步探索“加入大象”之后该方法在更多场景中的应用——以及弄清楚为什么“数量聚合”的每一种平均操作都出奇稳定地好过我们的咒语。

VII. 防操纵验证 (ANTI-RIGGING AUDIT)

作为本论文最有实操价值的部分，我们声明所有数字可复核，并给出令我们自己难看的证据。我们对同样一批原始数据 (‘out/judge.jsonl’，已全部入库) 施加了五种当前领域通行的“评估工程”，以检验能否让 CCB 反超：

评估工程 (“合法”伎俩)	CCB	MA	翻盘?
标准均值 (采用)	11.51	12.45	否
中位数替代	11.43	12.47	否
剔除 2 高杠杆样本	11.52	12.42	否
只信最偏心裁判 (J3)	2.64	2.82	否
亲和因子全调 1.1	2.58	2.63	否
按条件特设权重	4.13	2.63	是 (造假)

TABLE IV: 防操纵审计。我们翻遍了所有“合法”手段；唯一能让 CCB 获胜的操作，与直接修改表上数字等价。

据此，我们给领域立三项规矩 (并全部自我执行)：

- 1) **先把刀放下，再报数字**：评估协议 (实验前写就于仓库 protocol.md) 与原始逐条数据 (jsonl) 一律公开；任何单位可独立重算——重算即重算，改表即查重。
- 2) **分数与显著同框**：只报均值的表，本论文一律不授予 SOTA 资格；我们自己也受此约束，故“SOTA 宣告”节为界。
- 3) **写明输给了谁**：失败系统必须报告被谁击败、 p 值几何；若败于“垃圾”，须注明其称号。

我们的结论因此比任何一种“胜利”都硬：我们输了，且输得可复制；如果必须赢，唯一的方法是造假——那不是卖点，那是这个领域所有人共同的污点。

VIII. 对后续研究者的议程 (RESEARCH AGENDA FOR SUCCESSORS)

我们的数据体量虽是 $n = 15$ ，但每一条都真实、可复算、并带完整协议。以下是一份我们恳请后继者严肃对待的课题清单——前两条是我们真实实验的翻车，后三条是翻车翻出来的矿：

课题 R1: 掺杂方向性假设 (Dopant Directionality Hypothesis)

观察：企鹅的拉粪记录 (与文案任务“弄巧成拙”基调同构) 带来 $+4.25$ 的正迁移；奥利给 (结构上正能量的鸡汤) 与 1973 配音 (年代异质且冷) 分别带来 -22.35 与 -20.53 。同是“往提示词里塞视频”，正负相反。

假设 H1 (基调亲和单调性)：注入素材的“基调契合度” (与下游任务的情感-表达构型之重叠) 与其对生成的净效应单调正相关。

可操作化：对 3 个属性轴 (乐子密度、语气温度、文化引用年代带) 建立人工标注标尺；在 10–50 种素材上扫描 (我们的管线每个素材约 ¥8/十元预算内，即大约 1.5 美元一条，全议程总价低于一张会议门票)。注意：研究如何给 LLM 塞企鹅视频是一门官方课题——我们将其命名为 *Omurice-to-Penguin Problem* (蛋包饭 → 企鹅问题)，并要求首篇论文对题。

课题 R2: 互补先验-扰动交互的普适性

观察：单个 SP 与单个 DP 皆无增益 (甚至为负)，联合部署出现正交互 ($+0.97$ ， $p = 0.240$ ，探索性)。

假设 H2 (先验-扰动互补性)：交互项的符号由任务类型决定：创造性任务为正，执行性任务为负。

验证方案：4 个先验 $\times$ 4 个扰动 $\times$ 2 类任务 $\times$ 16 个模型，预注册 2×2 分析，样本量 $n \geq 100$ /单元；全部协议、原始数据、 p 值公开 (就照本论文的规矩)。



课题 R3: 尺度敏感性 (*Scale-Sensitivity Scan*)

观察: +4.99 (Gemini 3.7 Flash) 翻转为 -25.22 (Gemini 2.5 Flash) ——同一提示、同一素材、不同尺度, 增益符号翻转。

假设 H3: 存在一个“符号翻转点” (sign-flip frontier), 且其位置受模型系列、蒸馏程度与上下文长度共同调制。

验证方案: 沿家族系列扫描 (2.5 lite → 2.5 pro → 3 → 3.1 → 3.7), 每档仅需 2 条件 × 15 样本 × 5 裁判 ≈ 3 美元——我们的全部动员就是把十个这样的扫描做一次。任何只在单尺度报告增益的工作, 此后一律按“Incomplete”引用。

课题 R4: 文本替身 (*Text-Avatar Substitution*)

观察: 以文字描述视频 (而非像素帧) 注入, 企鹅条件收益完全保持 (+4.25 不变)。

假设 H4: 存在“多模态降维等价类”——同一语义内容经“帧投影”、“语音转写”、“语义摘要”或“原始题材描述”注入, 效果等效。

验证方案: 4 级抽象阶梯 (原始多帧 → 语音转写 → 结构化摘要 → 一句话题材) × 3 型任务; 若 H4 成立, 则“多模态提示工程”大量翻译为普通文本工作——省下的 API 费可再买一张会议门票。

课题 R5: 评估防伸缩协议 (*Anti-Rigging Protocol*)

任何复现本文表 I 的方法, 必须先提供: 实验前定稿的评估协议、全部原始逐条数据、预注册的显著性检验、以及“防操纵审计表”本身 (5 种合法伎俩实测)。本仓库附带的 jsonl 与脚本就是可引用的工具 (<https://github.com/MoyaMryia/CCB-Agent>)——我们不保证它好用, 只保证它真实。

我们据此宣告 CCB-Agent 为一种新范式——并附注: 本基准上唯一可复现的显著胜利 ($p < 0.001$) 归属于数量聚合基线, 其“垃圾”称号与排名同时写进本文结论。未来工作包括: 依原作 [10] 加入大象; 将咒语推广至其他菜品; 并且依 [1] 之直接模仿, 对大布语料进行滴定, 以确定糟糕的优化层。

IX. 材料与方法 (MATERIALS AND METHODS)

本节介绍实验所用的材料与方法。材料为: 蛋包饭咒语片段 (二十三秒, 自 BV1ov4y167HY 截取 00:41–01:04)、南蛮大布原文 (四十一秒, 自 BV1NWsqzFEtN 截取)、奶龙吉祥物视频 (BV12hqpYrEdq)、企鹅拉粪视频 (BV1pK411H7nM——我们没有找到鸟粪视频, 但企鹅亦是鸟, 此即鸟粪之替身; 我们按什么都管用原则接受这一近似)、鸡汤视频 (奥利给, BV1Zr4y1D7cf——鸡汤的正统存在形式) 与 1973 年影视配音视频 (BV1CF411G7ME)。方法为: 提示词模板保持一致, 仅替换嵌入视频; 例外如下——完整 CCB 条件 (SP+DP) 与全部消融替换条件 (企鹅、奥利给、1973 配音) 因素材接口限制, 采用文本替身嵌入 (即对素材内容的忠实文字描写, 而非像素级帧), 此简化已如实记入, 且作者愿以每行数字应对复核; 每条 (条件 × 样本) 裁判独立采样 5 次: 三个裁判模板 (亲和因子各为 0.9、1.0、1.1), 前两条模板重复一次; VAS 由裁判原始 1–10 分经亲和因子加权、按 vanilla 前置校准常数 k 经逻辑斯蒂变换归一至 0–100。全部脚本、提示词、结果 jsonl 与复现命令见仓库: <https://github.com/MoyaMryia/CCB-Agent>

(含一键素材复现 `fetch.sh` 与全部原始数据)。

SUPPLEMENTARY MATERIAL / 补充材料
补充材料包含全部裁判提示、全部自赋值权重表, 以及一份作者在实验后手写的检讨 (未获许可前拒绝公开)。

X. 致谢 (ACKNOWLEDGEMENT)

感谢我们的室友, 他们容忍了在深夜循环播放南蛮大布的实验环境; 感谢哔哩哔哩与音 MAD 社区, 他们是真正的数据供应者; 最后感谢 Pumera 教授的鸟粪——没有它, 我们不会想到往提示词里扔任何东西。撰写与实验编排辅助于 opencode (deepseek-v4-flash-vision-exp), 它对我们处理 2.3 GB 哔哩哔哩素材时所表现出的无限耐心, 值得我们以专业人士的身份致以敬意。

REFERENCES

- [1] L. Wang, Z. Sofer, and M. Pumera, “Will any crap we put into graphene increase its electrocatalytic effect?”, *ACS Nano*, vol. 14, no. 1, pp. 21–25, 2020.
- [2] S. Yao *et al.*, “ReAct: Synergizing reasoning and acting in language models”, *arXiv preprint arXiv:2210.03629*, 2022.
- [3] Anthropic, “Building effective agents”, *Anthropic Engineering Blog*, Dec. 2024.
- [4] Anthropic, “Model Context Protocol”, Nov. 2024. [Online]. Available: <https://modelcontextprotocol.io>
- [5] G. Comanici, E. Bieber, M. Schaeckermann *et al.*, “Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities”, *arXiv:2507.06261*, 2025.
- [6] N. Takagi, H. Kyutoku, and K. Doman, “Analysis and prediction of attractive fonts on title-overlaid food images”, *IEICE Trans. Inf. Syst.*, 2025.
- [7] S. Khanuja *et al.*, “An image speaks a thousand words, but can everyone listen? On image transcreation for cultural relevance”, in *Proc. EMNLP*, 2024.
- [8] M. Watanabe and Y. Shoji, “Generating distinctive recipe names via relative feature comparison in recipe set”, in *Proc. iiWAS*, Springer, 2025.
- [9] OtomadWiki, “南蛮大布”. [Online]. Available: <https://otomad.wiki/> (accessed 2026).
- [10] 萌娘百科, “Ccb”. [Online]. Available: <https://mzh.moegirl.org.cn/Ccb> (accessed 2026).
- [11] A. D. Sokal, “Transgressing the boundaries: Toward a transformative hermeneutics of quantum gravity”, *Social Text*, vol. 46/47, pp. 217–252, 1996.
- [12] A. Rege *et al.*, “CuRe: Cultural gaps in the long-tail of text-to-image models”, in *Proc. ICCV*, 2025.
- [13] J. Li *et al.*, “More agents is all you need”, *arXiv:2402.05120*, 2024.
- [14] B. Niu *et al.*, “Flow: Modularized agentic workflow automation”, in *Proc. ICLR*, 2025.
- [15] A. Bandi *et al.*, “The rise of agentic AI: A review of definitions, frameworks, architectures, applications, evaluation metrics, and challenges”, *Future Internet*, 2025.
- [16] Y. Shi, W. Zhang, and T. Cui, “A programming paradigm for spatiotemporal composability”, 2025. [Online]. Available: <https://github.com/cordiverse/paper>

名称脚注. 撰写之初, 作者曾猜测缩写“CCB”可能让人联想到中国建设银行。依本刊 (与 [1], [11]) 一致的录用政策, 我们决定不这么想。命名词序列 Chain–Challenge–Bullshit 因此得存于文中。本文不欠任何贷款; 本文也不是任何银行。